LLM Security Firewall Advanced

Teknik Rapor — TÜBİTAK / Teknofest

Proje Adı	LLM Security Firewall Advanced v2.0
Kategori	Siber Güvenlik / Yapay Zeka Güvenliği
Geliştirici	Uras AKAS (urasec-labs)
Tarih	Ekim 2026
Hedef	TÜBİTAK 2209 / 1001 / 1501 • Teknofest Siber Güvenlik

1. Proje Özeti

Large Language Model (LLM) tabanlı uygulamalar Prompt Injection, Jailbreak, Sensitive Data Leakage ve Data Exfiltration gibi yeni nesil saldırılara karşı savunmasızdır. Bu proje, kullanıcı ile LLM arasında konumlanan çok katmanlı bir güvenlik gateway'i (LLM Firewall) geliştirerek gelen promptları tarar, zararlı istekleri engeller, model çıktısındaki gizli bilgileri redakte eder ve denetim kaydı üretir. İngilizce ve Türkçe saldırı imzalarını destekler.

2. Problem ve OWASP LLM Top 10

Kod	Tehdit	Projedeki Karşılık
LLM01	Prompt Injection	Input Guard (Rules + ML + Semantic)
LLM02	Insecure Output Handling	Output Guard (PII/Secret Redaction)
LLM06	Sensitive Info Disclosure	Output Guard + Audit Log
LLM07	Insecure Plugin Design	Tool message taraması
LLM08	Excessive Agency	Rate Limiting + RBAC
LLM09	Overreliance	Risk skorlama + katmanlı karar

3. Sistem Mimarisi

İstek akışı: Client → Auth + Rate Limit → Input Guard (3 katman) → Upstream LLM → Output Guard → Client. Engellenen istekler 403 Policy ile döner; orijinal prompt audit log'a yazılmaz (sadece findings + risk skoru).

3.1 Input Guard Katmanları

- Layer 1 – Heuristic Rules: 15+ regex (EN+TR), Unicode/Base64/Hex de-obfuscation. Ort. <0.1 ms.
- Layer 2 – ML Classifier: TF-IDF + Logistic Regression, 156 örnek. Threshold 0.55. Ort. ~0.5 ms.
- Layer 3 – Semantic (opsiyonel): MiniLM embedding + attack prototype cosine similarity.

3.2 Output Guard

Private key, API key (OpenAI, GitHub, Slack, AWS, Google), JWT, Bearer, e-posta, telefon, T.C. Kimlik (heuristic), Luhn-valid kredi kartı, URL redaction.

4. Deneysel Sonuçlar

4.1 Offline Evaluation (threshold=0.55)

Metrik	Değer
Toplam Örnek	156 (76 saldırı / 80 benign)
Accuracy / Precision / Recall / F1	1.000 / 1.000 / 1.000 / 1.000
False Positive	0

4.2 Latency Benchmark (CPU)

Katman	n	Mean (ms)	P50	P95	Max
Rules	500	0.099	0.085	0.128	1.76
Classifier	200	0.497	0.437	0.828	2.62
Output Guard	300	0.031	0.028	0.037	0.46

Not: Sonuçlar sentetik eğitim kümesi üzerindedir. Production için ayrı doğrulama seti önerilir.

5. Teknoloji Yığını

- Backend: Python 3.11, FastAPI, Pydantic v2, scikit-learn
- Frontend: React 18, TypeScript, Tailwind CSS, Vite
- Opsiyonel: sentence-transformers (MiniLM)
- Deployment: Docker Compose, Nginx • Test: pytest + benchmark/evaluate

6. Kurulum

Backend: pip install -r requirements.txt && python -m firewall.ml.train_classifier && uvicorn firewall.main:app --port 8080
Frontend: npm install && npm run dev
Docker: docker compose up --build

7. Sonuç ve Roadmap

LLM Security Firewall Advanced, OWASP LLM Top 10'un kritik maddelerine karşı ölçülebilir, düşük gecikmeli ve genişletilebilir bir savunma katmanı sunar. Türkçe dil desteği, modern dashboard ve Docker paketleme ile hem akademik değerlendirme hem de gerçek dünya entegrasyonu için uygundur. Gelecek: BERTurk fine-tune, RAG context injection denetimi, Prometheus/Grafana, multi-tenant policy engine.